

Análisis de datos

Carrera de Especialización en
Inteligencia Artificial

Bimestre 1B2026



Docentes



Esp. Lic. María Carina Roldán
macroldan@fi.uba.ar

Esp. Ing. Ariadna Garmendia
arigarmendia@gmail.com

Objetivos de la materia

- 1 Aprender a realizar un análisis exploratorio de datos en detalle.
- 2 Entender qué mecanismos existen para el tratamiento de datos y cuáles son recomendados para el entrenamiento de un modelo de ML.



Enfoque

1

Vamos a ver un enfoque práctico y aplicado de los conceptos que se ven en otras materias (matemática, proba, etc.)

2

En AdD analizamos y preparamos datos para ser entrenados con modelos de ML.



Seteando expectativas sobre la materia

- 1 AdD no es un curso de bibliotecas de Python
- 2 AdD no es un curso de visualización
- 3 AdD no es un curso avanzado de análisis de datos
- 4 En AdD no entrenamos modelos



Método de evaluación




ACTIVIDADES GRUPALES
(OBLIGATORIAS)

6 PUNTOS



ACTIVIDADES INDIVIDUALES
(OPTATIVAS)

4 PUNTOS



Actividades grupales

- Son obligatorias.
- Todas están relacionadas con el trabajo final que explicaremos al final de la clase.



ACTIVIDADES GRUPALES (obligatorias)

Actividad	Consigna	Fecha límite de entrega	Exposición	Puntaje
1 - Armado de grupos	Mar 4, 2026	Mar 11, 2026	-	-
2 - Presentación EDA	Mar 11, 2026	Mar 17, 2026	Mar 18, 2026	1
3 - Presentación Final	Mar 4, 2026	Apr 21, 2026	Apr 22, 2026 (*)	5
			Apr 25, 2026 (*)	

(*) Se desdoblán las exposiciones en dos sesiones



Actividades individuales

- Son actividades sencillas pensadas para reforzar los conceptos vistos en clase.
- No se aceptan entregas fuera de la fecha límite.
- No es obligatorio hacerlas (pero no hacerlas impacta en la nota!)

ACTIVIDADES INDIVIDUALES (opcionales)



Actividad	Consigna	Fecha límite de entrega	Puntaje
1	Mar 4, 2026	Mar 10, 2026	1
2	Mar 11, 2026	Mar 21, 2026	1
3	Mar 18, 2026	Mar 28, 2026	2



¿Puedo usar LLMs?

- Sí! estamos en una carrera de IA. Las actividades y el trabajo son "a libro abierto" (o "a ChatGPT abierto" 😊).
- Sin embargo, tienen que demostrar que aprendieron los conceptos de la materia. Generar todo con IA y hacer entregas sin analizar no es el objetivo.
- Los LLMs se equivocan! úsenlos con criterio, cuestionen y verifiquen.

Programa de la materia

1 Introducción al análisis de
datos
4/3

2 Análisis exploratorio de
datos (EDA)
11/3

3 Taller práctico - parte 1
18/3

4 Preprocesamiento y
limpieza de datos
25/3

5 Procesamiento
(continuación)
1/4

6 Reducción de
dimensionalidad
8/4

7 Taller práctico - parte 2
15/4

8 Exposición final
22/4 y
25/4

Programa de la materia (detallado)



1

Introducción al análisis de datos

4/3

Flujo de trabajo típico. Aplicaciones. Configuración del entorno. Introducción a las principales bibliotecas. Introducción al EDA.

2

Análisis exploratorio de datos (EDA)

11/3

EDA. Estadística robusta. Visualización de variables numéricas y categóricas. Relación entre variables. Data cleaning y data wrangling. Identificación de valores faltantes y outliers.

3

Taller práctico - parte 1

18/3

Presentación de grupos de trabajo final. Práctica en salas virtuales: EDA y visualización inicial de un dataset. Puesta en común.

4

Preprocesamiento y limpieza de datos

25/3

Flujo de preparación de datos. Prevención de data leakage. Tratamiento de datos faltantes y outliers. Cardinalidad. Codificación. Discretización.

5

Procesamiento (continuación)

1/4

Normalización y estandarización. Técnicas avanzadas para el tratamiento de datos faltantes y outliers. Desbalance. Creación de nuevos features.

6

Reducción de dimensionalidad

8/4

Análisis estadístico inferencial. Técnicas para selección y extracción de features.
Bonus: EDA de datos no estructurados.

7

Taller práctico - parte 2

15/4

Práctica en salas virtuales: preprocesamiento y feature engineering de un dataset. Puesta en común.
Bonus: Herramientas para automatizar el EDA.

8

Exposición final

22/4 y
25/4

Exposición de trabajos finales (dos sesiones)

Información útil


- 1 Material de clase: Campus posgrado
- 2 Notebooks: Repositorio de la materia



Repositorio e instalación



Análisis de datos



¿Qué es el análisis de datos?



Es el proceso de explorar, limpiar y modelar datos para extraer información útil y tomar decisiones.


Es clave para garantizar que los modelos de IA trabajen con datos confiables y adecuados para el problema.







**¿Tienen experiencia
con análisis de datos?
¿Qué tareas incluye?**

Roles en datos y ML



Flujo de trabajo del análisis de datos para IA



1 Identificar el problema



2 Recopilar los datos.



3 EDA y limpieza básica



5 Entrenar modelos



4 Análisis estadístico y preparación

Bibliotecas para la implementación del flujo de trabajo



Recolección de datos

BeautifulSoup SQLAlchemy

Otras (otros tipos de datos, automatización)



EDA, preprocesamiento, limpieza

pandas

NumPy

Visualización y análisis

matplotlib

seaborn

Análisis estadístico, reducción de dimensionalidad


scikit learn

SciPy

statsmodels



Pandas. Terminología básica



Etiqueta única para
identificar filas
(observaciones)

Índice

Series

Columna de datos (features) con
etiquetas (nombres de columna)

DataFrame

Tabla bidimensional
(dataset completo)



Pandas. Documentación

Sitio oficial





About us Getting started Documentation Community Contribute

Latest version: 3.0.1

- What's new in 3.0.1
- Release date: Feb 17, 2026
- Documentation (web)
- Download source code

Follow us

Recommended books


Python for Data Analysis


Pandas Cookbook

pandas

pandas is a fast, powerful, flexible and easy to use open source data analysis and manipulation tool, built on top of the Python programming language.

[Install pandas now!](#)

Getting started

- Install pandas
- Getting started
- Try pandas online

Documentation

- User guide
- API reference
- Asking questions to pandas
- Release notes

Community

- About pandas
- Ask a question
- Ecosystem

With the support of:



The full list of companies supporting pandas is available in the [sponsors page](#).

Cheatsheet



Data Wrangling with pandas Cheat Sheet

<http://pandas.pydata.org>

[Pandas API Reference](#) [Pandas User Guide](#)

Creating DataFrames

```
df = pd.DataFrame({
    "a": [4, 5, 6],
    "b": [7, 8, 9],
    "c": [10, 11, 12],
    index = [1, 2, 3]
})
```

Specify values for each column.

```
df = pd.DataFrame(
    [[4, 7, 8],
     [9, 8, 11],
     [6, 9, 12]],
    index=[1, 2, 3],
    columns=['a', 'b', 'c'])
```

Specify values for each row.

	a	b	c
1	4	7	8
2	9	8	11
3	6	9	12

Tidy Data - A foundation for wrangling in pandas

Tidy data complements pandas's vectorized operations. pandas will automatically preserve observations as you manipulate variables. No other format works as intuitively with pandas.

In a tidy data set: Each variable is saved in its own column. Each observation is saved in its own row.

$M \times N \times A$

Reshaping Data - Change layout, sorting, reindexing, renaming

pd.melt(df)
Gather columns into rows.

df.pivot(columns="var", values="val")
Spread rows into columns.

pd.concat([df1, df2])
Append rows of DataFrames.

pd.concat([df1, df2], axis=1)
Append columns of DataFrames.

```
df.sort_values("age")
```

Order rows by values of a column (low to high).

```
df.sort_values("age", ascending=False)
```

Order rows by values of a column (high to low).

```
df.rename(columns={"y": "year"})
```

Rename the columns of a DataFrame.

```
df.reset_index()
```

Sort the index of a DataFrame.

```
df.reset_index()
```

Reset index of DataFrame to row numbers, moving index to columns.

```
df.reset_index(["length", "weight"])
```

Drop columns from DataFrame.

Subset Observations - rows

df[df.length > 7]
Extract rows that meet logical criteria.

df.drop_duplicates()
Remove duplicate rows (only considers columns).

df.sample(frac=0.5)
Randomly select fraction of rows.

df.sample(n=8)
Randomly select n rows.

df.iscase("value")
Select and order top n entries.

df.sortindex("value")
Select and order bottom n entries.

df.head(n)
Select first n rows.

df.tail(n)
Select last n rows.

Subset Variables - columns

df[["width", "length", "species"]]
Select multiple columns with specific names.

df["width"] or **df.width**
Select single column with specific name.

df.filter(regex="paper")
Select columns whose name matches regular expression.

Using query

query() allows Boolean expressions for filtering rows.

```
df.query("length > 7")
```

Select rows meeting logical condition, and only the specific columns.

```
df[df["length"] > 7 and df["width"] < 8]
```

Access single value by index.

```
df.at["a", "b"]
```

Access single value by label.

```
df.iat["a", "b"]
```

Logos in Python (and pandas)

Less than	To	Not equal to
<	df.x < df.y	df.x != df.y
>	df.x > df.y	df.x > df.y
<=	df.x <= df.y	df.x <= df.y
>=	df.x >= df.y	df.x >= df.y

Regex (Regular Expressions) Examples

Regex	Matches
^%	Matches strings containing a percent sign
^long\$	Matches strings ending with word "long"
^paper\$	Matches strings beginning with word "paper"
^%&32\$	Matches strings beginning with % and ending with 32.000
^%\$	Matches strings except the string "Percent"

Ejemplos prácticos en Jupyter






¿Qué es el análisis exploratorio de datos (EDA)?

- El análisis exploratorio sirve para resumir, visualizar y entender los datos.
- Útil para tomar decisiones sobre el manejo de outliers y datos faltantes.
- Ayuda a identificar transformaciones necesarias antes de entrenar modelos de ML: escalamiento, normalización, balance, codificación, discretización, etc.
- Facilita la identificación de patrones, relaciones y la evaluación de la relevancia de los datos.


Variables aleatorias y datasets

- Una variable aleatoria (v.a.) es una forma de mapear los resultados de algún fenómeno aleatorio a números.
- Constituyen una herramienta fundamental para modelar y analizar fenómenos que involucran incertidumbre o aleatoriedad.
- Las columnas de un dataset pueden considerarse como un conjunto de observaciones (una muestra) de una variable aleatoria, tomada de una población más grande.



El dataset del Titanic

- Es un dataset muy famoso para aprender IA.
- Lo vamos a estar usando a lo largo del curso para aprender ciertos conceptos.
- Contiene información de pasajeros del barco, sus características (entre otros datos, contiene: edad, género, clase en la que viajaban, costo del pasaje, con cuántos familiares viajaban, etc.), y si sobrevivieron o no.



Ejemplos de v. aleatorias en el dataset del Titanic

Columna	Fenómeno aleatorio
Survived (¿sobrevivió?)	Varía aleatoriamente según factores como la ubicación en el barco, el acceso a botes salvavidas, la clase social y decisiones personales durante el naufragio.
Sex	Varía aleatoriamente según la composición de quienes decidieron o pudieron viajar. Influenciada por factores sociales como roles de género o motivos del viaje.
Age	Variable en función de la población que decidió o pudo viajar en el Titanic. Condicionada por el año de nacimiento de las personas y las circunstancias que los llevaron a ese viaje.
SibSp (cantidad de hermanos o esposo/a)	Influenciada por decisiones familiares (ej., viajar juntos), tamaño de la familia y factores sociales de la época.
Fare (tarifa)	Variable según factores como la clase (primera, segunda, tercera), el puerto de embarque o decisiones individuales de compra.
Embarked (puerto de embarque)	Influenciada por el lugar de origen, itinerario personal y disponibilidad de pasajes desde cada puerto.

Tipos de variables

Cosas que puedo contar o medir

Cuantitativas (numéricas)

Discretas

Toman valores enteros

Cantidad de hijos

Número de visitas al médico

Número de ventas

Continuas

Pueden tomar cualquier valor dentro de un rango

Temperatura

Altura

Edad

Cualidades o información que no se puede medir

Categóricas (cualitativas o atributos)

Nominales

Sin orden

Estado civil

Nombre de ciudad

Día de la semana

Ordinales

Tienen un orden específico (jerarquía o magnitud)

Talles de ropa (S, M, L)

Opiniones (muy de acuerdo, de acuerdo,...)

Nivel de educación (secundario, terciario, universitario)

Algunas consideraciones interesantes

- Una variable categórica se puede representar con números (que actúan como un encoding).
- La **edad** en general se considera una variable continua pero generalmente se mide y reporta como discreta (Ej., en años). → Naturaleza de los datos vs. cómo se refleja.
- Las variables **binarias** (Sí/No, 1/0, True/False) son un caso particular de las categóricas nominales.
- Las **fechas** tienen una doble naturaleza:
 - Numérica, cuando interesa medir tiempo transcurrido o tendencias.
 - Categórica, cuando interesa agrupar eventos en una fecha específica (Ej., analizar las ventas en un día particular de la semana).
- ¿Qué pasa con las **coordenadas geográficas**?



Ejercicio opcional

Resolver el ejercicio de la Notebook `clase_01_ejercicio.ipynb` (se encuentra en la carpeta "recursos" del repositorio).



Descripción del trabajo y presentación grupal



CONSIGNA





Presentación grupal

- La **exposición grupal** es en la última clase y se desdoblará en dos sesiones.
- Se recomienda hacer avances y realizar consultas semanalmente, incorporando los conceptos vistos en cada clase.
- En la presentación es obligatorio que estén todos los integrantes del grupo. No estar presente implica desaprobación de la materia.
- La nota surgirá de la calidad de la exposición.

ACTIVIDAD GRUPAL 1

Armado de grupos para el trabajo final

Plazo para tener definidos los
grupos de trabajo:

martes 10/3/26



Planilla con los grupos



ACTIVIDAD INDIVIDUAL 1

1 PUNTO

OBJETIVO

- Identificar y seleccionar un dataset real.
- Familiarizarse con las bases de datos y repositorios abiertos, las interfaces de descarga, los distintos tipos de archivos y metadatos.

Plazo para completar la actividad:

martes 10/3/26



ACTIVIDAD



¿Te quedaron dudas?



- Recordá que podés consultarnos durante la clase preniendo la cámara y hablando, o simplemente escribiendo en el chat.
- También podés escribirnos por correo las veces que sea necesario (por favor incluir a ambas docentes).



Esp. Lic. María Carina Roldán
macroldan@fi.uba.ar



Esp. Ing. Ariadna Garmendia
arigarmendia@gmail.com

Y si tenés un feedback, un pedido, una sugerencia, etc. y no te animás a decirlo, podés dejarlo por escrito en la encuesta voluntaria y anónima (disponible durante todo el bimestre).