

Análisis de datos

Carrera de Especialización en
Inteligencia Artificial
BI 2026



Programa de la materia (detallado)

1

Introducción al análisis de datos

4/3

Flujo de trabajo típico. Aplicaciones. Configuración del entorno. Introducción a las principales bibliotecas. Introducción al EDA.

2

Análisis exploratorio de datos (EDA)

11/3

EDA. Estadística robusta. Visualización de variables numéricas y categóricas. Relación entre variables. Data cleaning y data wrangling. Identificación de valores faltantes y outliers.

3

Taller práctico - parte 1

18/3

Presentación de grupos de trabajo final. Práctica en salas virtuales: EDA y visualización inicial de un dataset. Puesta en común.

4

Preprocesamiento y limpieza de datos

25/3

Flujo de preparación de datos. Prevención de data leakage. Tratamiento de datos faltantes y outliers. Cardinalidad. Codificación. Discretización.

5

Procesamiento (continuación)

1/4

Normalización y estandarización. Técnicas avanzadas para el tratamiento de datos faltantes y outliers. Desbalance. Creación de nuevos features.

6

Reducción de dimensionalidad

8/4

Análisis estadístico inferencial. Técnicas para selección y extracción de features.
Bonus: EDA de datos no estructurados.

7

Taller práctico - parte 2

15/4

Práctica en salas virtuales: preprocesamiento y feature engineering de un dataset. Puesta en común.
Bonus: Herramientas para automatizar el EDA.

8

Exposición final

22/4 y
25/4

Exposición de trabajos finales (dos sesiones)

ACTIVIDAD INDIVIDUAL 2

El dataset más elegido fue

Gaming and Mental Health

Otros datasets elegidos en la misma categoría

Social Media and Mental Health

Students' Social Media Addiction

Mental Health Disorder Risk Assessment



ACTIVIDAD INDIVIDUAL 2

¿Hubo algo que hubieras querido hacer pero aún no tenés los conocimientos o herramientas?




- Explotar mejor la información disponible (> experiencia)
- Análisis más avanzado (> conocimiento)
- Explotar / analizar información geoespacial
- Análisis temporal (estacionalidad, tendencias)
- Extraer información mediante técnicas de PLN
- Modelos predictivos
- Tratamiento de outliers / Tratamiento de faltantes
- Hacer feature engineering

Flujo de trabajo del análisis de datos para IA



Flujo de preparación de datos para IA



Data leakage

Es un problema que sucede cuando cierta información que no se suponía que el modelo debía conocer, se filtra al momento del entrenamiento.


El modelo hace “trampa” en vez de aprender patrones reales.



Como resultado, al evaluar el modelo se obtienen métricas de desempeño engañosas (demasiado optimistas) y mala performance con datos nuevos.

Tipos de data leakage

- Target leakage
- Contaminación train-test



Target leakage

Ocurre cuando, para el entrenamiento, se usan:


- Features cuyo valor no está disponible al momento de la predicción.
- Features que actúan como predictores perfectos o casi perfectos del target (es decir, básicamente lo delatan o es incluso la misma información). En este caso deja de tener sentido el problema de ML.



Ejemplo 1: target leakage

Una empresa quiere predecir si su campaña de marketing via emails (links en el cuerpo del email) va a ser exitosa:


email_ID	subject	clicleo_links	TARGET: abrio_email
1	Artículos recomendados de esta semana	FALSE	TRUE
2	Esto no es una venta. Es una celebración!	FALSE	FALSE
3	NO TE LO PIERDAS!! 50% OFF en calzado	FALSE	FALSE
4	Todo por menos de \$29,99!	TRUE	TRUE



Ejemplo 1: target leakage

Una empresa quiere predecir si su campaña de marketing via emails (links en el cuerpo del email) va a ser exitosa:

email_ID	subject	clicleo_links	TARGET: abrio_email
1	Artículos recomendados de esta semana	FALSE	TRUE
2	Esto no es una venta. Es una celebración!	FALSE	FALSE
3	NO TE LO PIERDAS!! 50% OFF en calzado	FALSE	FALSE
4	Todo por menos de \$29,99!	TRUE	TRUE



Ejemplo 2: target leakage

Se quiere predecir si un paciente tiene anemia.

edad	hace_deporte	nivel_hemoglobina	restricciones_alimentarias	manifiesta_mareos	TARGET: tiene_anemia
23	No	normal	Celíaco	No	FALSE
49	Sí	bajo	No	Sí	TRUE
33	Sí	normal	Vegetariano	No	FALSE
81	No	bajo	No	No	TRUE

Ejemplo 2: target leakage

Se quiere predecir si un paciente tiene anemia.

edad	hace_deporte	nivel_hemoglobina	restricciones_alimentarias	manifiesta_mareos	TARGET: tiene_anemia
23	No	normal	Celíaco	No	FALSE
49	Sí	bajo	No	Sí	TRUE
33	Sí	normal	Vegetariano	No	FALSE
81	No	bajo	No	No	TRUE

Tarea: Ejemplo 3

Un banco quiere usar IA para predecir transacciones fraudulentas, y entrena el modelo con estos datos:

transacción	fecha	hora	monto	reembolso_aprobado	intentos_fallidos	TARGET: es_fraude
123458	10/10/2025	18:17	1000	0	0	0
74720	11/10/2025	10:02	350	0	1	0
43843	12/10/2025	13:35	1500	1	3	1

Contaminación train-test

Ocurre cuando se entrena el modelo con información de los datos de test. Se testea con datos que el modelo ya vio indirectamente.

Sucede usualmente en la etapa de preprocesamiento de los datos o en el momento de hacer el split.



Ejemplo: contaminación train-test


Un profesor está entrenando a un grupo de alumnos en estadística y quiere evaluar cuánto aprendieron.

En el examen, les toma 5 ejercicios pero 3 de ellos son exactamente iguales a los vistos en la práctica.



Data leakage: red flags

- Uno o dos features dominan completamente la predicción (en general, cualquier variable que describa o revele el target, o que sea el target “disfrazado”).
- El modelo es demasiado bueno.
- La performance del modelo se desploma en producción.



Trucos para evitar data leakage

- Prevenir target leakage:
 - Evitar features que son consecuencia del target o que lo revelan directamente.
 - Verificar que los valores reflejen el estado al momento de predecir, no uno posterior.
- Prevenir contaminación train-test:
 - Realizar el split antes de cualquier preprocesamiento. Calcular las transformaciones sobre los datos de entrenamiento únicamente, y luego aplicarlas a los datos de test. Cuidado con los datos duplicados!



Consideraciones al hacer el split

x1	x2	target
01/2024		
...		
...		
04/2024		
...		
...		
09/2024		
10/2024		
...		
12/2024		

SERIE TEMPORAL

x1	x2	target
CLIENTE 1		
CLIENTE 1		
CLIENTE 1		
CLIENTE 2		
CLIENTE 2		
CLIENTE 3		
CLIENTE 3		
CLIENTE 4		
CLIENTE 4		
CLIENTE 5		

CLUSTERS DE DATOS

(El dataset contiene múltiples muestras de la misma entidad: clientes, pacientes, etc.)

TRAIN

TEST

Estrategias para manejo de datos faltantes y outliers


¿qué son los datos faltantes?

	F	G	H	I	J
A	0.620576	0.140053	1.352728	NaN	0.808078
B	NaN	0.526829	NaN	NaN	0.170902
C	NaN	0.458827	1.406713	0.071119	NaN
D	NaN	2.307197	NaN	NaN	NaN
E	0.203402	0.259913	NaN	0.505811	1.516755

Missing data

Son observaciones incompletas o valores no registrados en el dataset (NaN, null).


¿qué son los outliers?



Son puntos que difieren significativamente de otras observaciones en un dataset.

Si no se manejan adecuadamente, los datos faltantes y los outliers pueden distorsionar el análisis, introducir sesgo en los modelos y conducir a conclusiones erradas.

Estrategias para manejo de datos faltantes



Eliminación

- Borrar filas (observaciones).
- Borrar columnas (variables).

	F	G	H	I	J
A	0.620576	0.140053	1.352728	NaN	0.808078
B	NaN	0.526829	NaN	NaN	0.170902
C	NaN	0.458827	1.406713	0.071119	NaN
D	NaN	2.307197	NaN	NaN	NaN
E	0.203402	0.259913	NaN	0.505811	1.516755

Missing data

Imputación (colocar un valor)

- Métodos *univariados* (se usan los datos de la variable con faltantes).
 - Por media, mediana, moda.
 - Valor de adelante o de atrás.
 - Crear nueva categoría.
 - Series temporales: hacia adelante/atrás e interpolación lineal o polinómica.

Ejemplo: imputación por la mediana



columna original

Imputación

Mediana de la
edad = 28

sex	fare	class	deck	embark_town	alive	alone	age	age_2
male	26.5500	First	E	Southampton	yes	True	51.00	51.00
female	21.0750	Third	NaN	Southampton	no	False	3.00	3.00
female	19.2583	Third	NaN	Cherbourg	yes	False	0.75	0.75
male	7.2292	Third	NaN	Cherbourg	no	True	NaN	28.00
male	8.0500	Third	NaN	Southampton	no	True	34.00	34.00
female	23.0000	Second	NaN	Southampton	yes	False	18.00	18.00
female	27.7208	First	B	Cherbourg	yes	True	44.00	44.00
male	14.5000	Third	NaN	Southampton	no	True	NaN	28.00
male	9.5000	Third	NaN	Southampton	no	True	NaN	28.00
female	9.5875	Third	NaN	Southampton	no	True	37.00	37.00
male	11.5000	Second	NaN	Southampton	no	False	21.00	21.00
male	78.8500	First	C	Southampton	no	False	36.00	36.00

Histograma de la edad antes y
después de la imputación




Ejemplo: imputación hacia adelante/atrás

columna original

Imputación

	date	passengers	pass_ffill	pass_bfill
0	1949-01-01	NaN	NaN	118.0
1	1949-02-01	118.0	118.0	118.0
2	1949-03-01	132.0	132.0	132.0
3	1949-04-01	129.0	129.0	129.0
4	1949-05-01	NaN	129.0	135.0
5	1949-06-01	135.0	135.0	135.0
6	1949-07-01	148.0	148.0	148.0
7	1949-08-01	148.0	148.0	148.0
8	1949-09-01	136.0	136.0	136.0
9	1949-10-01	119.0	119.0	119.0
10	1949-11-01	NaN	119.0	126.0
11	1949-12-01	NaN	119.0	126.0
12	1950-01-01	NaN	119.0	126.0
13	1950-02-01	126.0	126.0	126.0

Número de pasajeros antes y después de la imputación



¿Cómo elegir la estrategia para el tratamiento de faltantes? 1/2


- Si los faltantes son MCAR:
 - Eliminación de fila cuando los datos faltantes representan 5-10% máx. del total de filas.
 - Eliminación de columna: >60-70% valores faltantes en la misma columna y la variable no es importante.
 - Atención: evaluar el impacto en la distribución de los datos antes de eliminar filas. Eliminar datos puede producir sesgo.
- Si son MCAR o MAR y el porcentaje de faltantes es bajo (10-30%):
 - Imputación por media: datos con distribución aprox. Normal.
 - Imputación por mediana (captura mejor relaciones no lineales pero depende de la calidad de otras variables y puede implicar más costo computacional).
 - Imputación por moda (variables categóricas) o nueva categoría (ej., "FALTANTE") si tiene sentido.
 - Atención: imputar con la media, mediana y moda modifican la varianza.

¿Cómo elegir la estrategia para el tratamiento de faltantes? 2/2

- Si son MAR con patrones claros y el porcentaje es moderado a alto (20-50%)
 - Técnicas avanzadas (las veremos más adelante)
- Si se sospecha de MNAR o MAR complejos (dependen de muchas variables):
 - Técnicas avanzadas (las veremos más adelante)
- Series temporales:
 - se elige una imputación específica según el tipo de serie (interpolación, modelos de series temporales como ARIMA, LSTMs, modelos generativos).

Estrategias para manejo de outliers

- **Eliminación.**
 - Si no son representativos o se los considera errores.
- **Imputación.**
 - Reemplazar por un valor acorde (media, mediana).
 - Aplicar winsorización (o *capping* en inglés): reemplazar por un valor máximo o mínimo definido, generalmente basado en un percentil.
- **Transformación** (Para minimizar el impacto)
 - Logarítmica (o raíz cuadrada)
- **Segmentación.**
 - Agrupar los outliers en una categoría separada (variables categóricas)



• Analizar si se trata de errores o son valores legítimos!

Ejemplos prácticos en Jupyter



Cardinalidad (v. categóricas)

Es el número de valores únicos que puede tomar una variable en un conjunto de datos.

Baja

La mayoría de los valores se repiten



Estado civil

Día de la semana

Alta

Muchos valores únicos



Nombres de clientes

Direcciones de correo electrónico

Extrema

Cada valor es único en la mayoría de los casos.



Números de serie

Códigos de transacciones

Codificación

- Consiste en transformar **variables categóricas** en **números** para que puedan ser utilizadas por algoritmos de ML.
- La elección de la estrategia de codificación depende del **tipo de variable** y de la **cardinalidad** de los datos.



Estrategias de codificación

Categóricas (cualitativas)

Nominales

Ordinales

One-hot

...	COLOR	...	...
...	AZUL	...	...
...	ROJO	...	...
...	VERDE	...	...
...	AZUL	...	...
...	VERDE	...	...
...	VERDE	...	...

↑
Feature que
queremos codificar

AZUL	ROJO	VERDE
1	0	0
0	1	0
0	0	1
1	0	0
0	0	1
0	0	1

↑
feature codificada

Estrategias de codificación

Categóricas (cualitativas)

Nominales

Ordinales

Hashing

...	COLOR	...	...
...	AZUL	...	...
...	ROJO	...	...
...	VERDE	...	...
...	AZUL	...	...
...	VERDE	...	...
...	VERDE	...	...

↑
Feature que
queremos codificar

H1	H2
0	1
1	0
1	1
0	1
1	1
1	1

↑
feature codificada

Hashing encoding: aclaraciones

- En general es la solución preferida cuando se tienen variables categóricas con cardinalidad muy alta y se trabaja con pipelines simples y modelos de ML tradicional.
- Los enfoques híbridos con *embeddings** pre-entrenados son una alternativa, pero implican mayor complejidad. Por lo general se usan para capturar semejanzas semánticas entre categorías.

ID_EMPL	TITULO	SUELDO
E00001	MACHINE LEARNING ENGINEER	...
E00002	SENIOR SOFTWARE DEVELOPER	...
E00003	ANALISTA DE RECURSOS HUMANOS	...
...	...	...

(*) *Embeddings* se explica en detalle en la materia Aprendizaje Profundo.

Estrategias de codificación

Categorías (cualitativas)

Nominales

Ordinales

Frequency encoding

...	COLOR	...	...
...	AZUL	...	...
...	ROJO	...	...
...	VERDE	...	...
...	AZUL	...	...
...	VERDE	...	...
...	VERDE	...	...

↑
Feature que
queremos codificar

COLOR_F
0.333
0.166
0.5
0.333
0.5
0.5


↑
feature codificada

$$\text{Azul} = 2/6 = 0.333$$

$$\text{Rojo} = 1/6 = 0.166$$

$$\text{Verde} = 3/6 = 0.5$$

Estrategias de codificación



Target encoding

...	COLOR	...	PRECIO
...	AZUL	...	8
...	ROJO	...	10
...	VERDE	...	5
...	AZUL	...	16
...	VERDE	...	7
...	VERDE	...	3

COLOR_T
12
10
5
12
5
5

$$\text{Azul} = (8 + 16) / 2 = 12$$

$$\text{Rojo} = (10) / 1 = 10$$


$$\text{Verde} = (5 + 7 + 3) / 3 = 5$$

↑
Feature que
queremos codificar

↑
target

↑
feature codificada

Estrategias de codificación



Target encoding

...	COLOR	...	PRECIO	COLOR_T
...	AZUL	...	8	12
...	ROJO	...	10	10
...	VERDE	...	5	5
...	AZUL	...	16	12
...	VERDE	...	7	5
...	VERDE	...	3	5

↑
Feature que
queremos codificar

↑
target

↑
feature codificada

Para reducir el data leakage se puede implementar una variante:

- k-fold target encoding
- leave-one-out target encoding

[Video](#)

Estrategias de codificación

Categorías (cualitativas)

Nominales

Ordinales

Ordinal

...	CALIDAD	...	...
...	BUENA	...	...
...	REGULAR	...	...
...	MUY BUENA	...	...
...	BUENA	...	...
...	MUY BUENA	...	...
...	MUY BUENA	...	...

Feature que
queremos codificar

CALIDAD_O
1
0
2
1
2
2

feature codificada

Caso particular:


Variables con comportamiento cíclico

date	month	month_num	month_sin	month_cos
1949-01-01	Jan	1	0.5000	0.8660
1949-02-01	Feb	2	0.8660	0.5000
1949-03-01	Mar	3	1.0000	0.0000
1949-04-01	Apr	4	0.8660	-0.5000
1949-05-01	May	5	0.5000	-0.8660
1949-06-01	Jun	6	0.0000	-1.0000
1949-07-01	Jul	7	-0.5000	-0.8660
1949-08-01	Aug	8	-0.8660	-0.5000
1949-09-01	Sep	9	-1.0000	-0.0000
1949-10-01	Oct	10	-0.8660	0.5000
1949-11-01	Nov	11	-0.5000	0.8660
1949-12-01	Dec	12	-0.0000	1.0000
1950-01-01	Jan	1	0.5000	0.8660
1950-02-01	Feb	2	0.8660	0.5000
1950-03-01	Mar	3	1.0000	0.0000

Feature que
queremos codificar

feature codificada

Cyclic encoding



Caso particular:

Problemas de CLASIFICACIÓN

...	...	...	TIPO_INCIDENCIA
...	...	...	problemas técnicos
...	...	...	consulta
...	...	...	consulta
...	...	...	reclamo factura
...	...	...	problemas técnicos
...	...	...	cambio de plan

↑
target

En un problema de CLASIFICACIÓN la variable target debe ser de tipo **numérica discreta**.



Si no lo es, tenemos que codificarla!

Codificación de la variable TARGET

EJEMPLO 1. Variable target categórica

...	...	...	TIPO_INCIDENCIA
...	...	...	problemas técnicos
...	...	...	consulta
...	...	...	consulta
...	...	...	reclamo factura
...	...	...	problemas técnicos
...	...	...	cambio de plan

↑
target

Label encoding

INCID_L
0
1
1
2
0
3

↑
target codificada

Codificación de la variable TARGET

EJEMPLO 2. Variable target numérica continua

...	...	...	PRECIO	PRECIO_D
...	...	...	8,66	CARO
...	...	...	10,15	MUY CARO
...	...	...	5,01	BARATO
...	...	...	8,16	CARO
...	...	...	7,90	BARATO
...	...	...	3	BARATO

↑
target

Label encoding

PRECIO_L
1
2
0
1
0
0

↑
target codificada

Ejemplos prácticos en Jupyter



RESUMEN de estrategias de codificación

Técnica	Consiste en ...	Ideal para...
One-Hot Encoding	crear una columna binaria (0/1) para cada categoría.	Baja cardinalidad. Multi-label (multi-hot encoding)
Ordinal Encoding	asignar un número entero secuencial a cada categoría.	Variables con un orden lógico
Hashing Encoding	aplicar una función hash para mapear categorías en un número fijo de dimensiones.	Cardinalidad muy alta
Frequency Encoding	sustituir cada categoría por su frecuencia de aparición.	Muchas categorías frecuentes (si hay categorías poco frecuentes, agrupar). Hay relación fuerte entre la frecuencia de una categoría y la variable target (ej. fraude)
Target Encoding	reemplazar cada categoría con la media (u otra estadística) de la variable objetivo.	Alta cardinalidad. Problemas supervisados
Cyclic Encoding	transformar variables cíclicas en coordenadas en un círculo mediante funciones seno y coseno.	Variables con patrón cíclico
Label Encoding	asignar un número entero arbitrario a cada categoría	Codificar la variable target


Estrategias de codificación. Ventajas y desventajas.

Técnica	Ventajas	Desventajas
One-Hot Encoding	Simple y efectiva	Escala mal con alta cardinalidad
Ordinal Encoding	Conserva el orden natural	Crea relaciones numéricas artificiales, (lineal, igualmente espaciada, por ej: low=1, medium=2, high=3) y puede confundir a los modelos lineales o basados en distancia
Hashing Encoding	Escalable y eficiente	Puede provocar colisiones (no es reversible) No conserva relaciones semánticas, orden ni jerarquía
Frequency Encoding	Útil para reducir categorías raras	Puede perder información
Target Encoding	Compacto y efectivo	Riesgo de sobreajuste
Cyclic Encoding	Conserva continuidad temporal	No se recomienda en datos sin periodicidad clara
Label encoding	Simple y efectiva	Pensado únicamente para la variable target (porque implica orden)


Discretización

- La discretización convierte **variables continuas** en variables discretas o **categorías**.
- Se usa para mejorar la interpretación o el rendimiento de un modelo.

Métodos de discretización




- Por intervalos de igual rango de valores.



- Por puntos de corte (cuantiles)

¿Para qué discretizamos?



- Para reducir la cantidad de datos y la complejidad computacional.
- Para disminuir el “ruido”: muchas veces los datos crudos incluyen fluctuaciones aleatorias o irrelevantes que contribuyen al overfitting.
- Para adaptar la variable target (convertir una variable continua a discreta) en un problema de clasificación.
- Para mejorar el entendimiento o la interpretación de un problema (por ejemplo, convertir edades de clientes en segmentos objetivo: joven, adulto, adulto mayor).
- Como herramienta para “contener” el efecto de los outliers.

Ejemplos prácticos en Jupyter



RESUMEN de métodos de discretización

Método	Descripción	Pros y contras
Intervalos iguales	Rangos de igual amplitud.	Simple. No sirve si los datos son asimétricos.
Por puntos de corte	Basados en la distribución de los datos. Cada intervalo tiene el mismo número de observaciones.	Funciona bien para datos asimétricos.
K-means	Agrupar los datos en clusters con el algoritmo k-means	Captura agrupamientos naturales. Para datasets grandes requiere mucho cómputo.
Ancho fijo	Definidos por el usuario basados en el conocimiento del dominio.	Control total, pero requiere conocimiento de los datos y su distribución.

¿Te quedaron dudas?



- Recordá que podés consultarnos durante la clase prendiendo la cámara y hablando, o simplemente escribiendo en el chat.
- También podés escribirnos por correo las veces que sea necesario (por favor incluir a ambas docentes).



Esp. Lic. María Carina Roldán
macroldan@fi.uba.ar



Esp. Ing. Ariadna Garmendia
arigarmendia@gmail.com

Y si tenés un feedback, un pedido, una sugerencia, etc. y no te animás a decirlo, podés dejarlo por escrito en la encuesta voluntaria y anónima (disponible durante todo el bimestre).